Лектор – *Сенько Олег Валентинович*

Курс «ПРИКЛАДНОЙ СТАТИСТИЧЕСКИЙ АНАЛИЗ ДАННЫХ. ЧАСТЬ II»
ПС

Перестановочный тест

Эффективным непараметрическим инструментом статистической верификации является перестановочный тест. Целью перестановочного теста является проверка существования зависимости между целевой переменной Y от и набором пременных $X_1, \ldots, X_n$ в рамках некоторой гипотезы о соответствующей математической модели. Проверка существования зависимости сводится к попытке опровержения нулевой гипотезы о независимости переменной Y от переменных $X_1, \ldots, X_n$ с использованием статистики, характеризующей качество аппроксимации зависимости с использование предложенной модели. Например, при гипотезе о существовании прямой линейной связи между Y и одной единственной переменной X статистикой может являться коэффициент корреляции Пирсона. При гипотезе о существовании линейной связи между Y и $X_1, \ldots, X_n$ статистикой критерия может служить величина R^2.

Перестановочный тест

Предположим, что у нас имеется выборка $\widetilde{S} = \{(y_1, \mathbf{x}_1), \ldots, (y_m, \mathbf{x}_m)\}$. Для использовании перестановочного теста необходимо:

- Сделать предположение о характере зависимости и предложить соответствующую этому предположению статитику T.
- Рассчитать значение статитики T для исходной выборки $\widetilde{S}$
- Выбрать количество перестановок N исходя из имеющихся ревычислительных ресурсов.
- Приравнять 0 целочисленны показатель N_t, подсчитывающей достижение или привышение статистики критерия при справедливости нулевой гипотезы H_0 (см.далее)
- А) С использованием генератора случаных чисел получить случайную перестановк f чисел из набора $\{1, \ldots, m\}$

Перестановочный тест

- B) По перестановке f построить случайную выборку $\widetilde{S}_r = \{(y_{f(1)}, \mathbf{x}_1), \ldots, (y_{f(m)}, \mathbf{x}_m)\}$
- C) Рассчитать значение статистики T для случайной выборки $\widetilde{S}_r$
- D) При выполнении неравенства $T(\widetilde{S}_r) \geq T(\widetilde{S})$ $N_t = N_t + 1$. В противном случае N_t не меняется.
- Независимо повторить пункты A)-D) N раз.
- В качестве $p-$значения использовать отношение $\frac{N_t}{N}$

Перестановочный тест.

Предположим, что $\widetilde{S}_r^j$ - выборка, полученная из исходной выборки $\widetilde{S}$ с использование случайной перестановки чисел из $\{1, \ldots, m\}$ с порядковым номером j. Приведённую выше процедуру подсчёта $p-$значения можно выразить формулой

$$p = \frac{\sum_{j=1}^{N} I[T(\widetilde{S}_r^j) \geq T(\widetilde{S})]}{N}, \tag{1}$$

где $I[b] = 1$ при $b = true$ и $I[b] = 0$ в противном случае.

Перестановочный тест. Обоснование.

В классической статистике $p-$значение определяется как $P(T \geq |T(S)|H_0)$ При этом в H_0 наряду с предположением о характеристиках распределений, из которых генерируются данные, входит также предположение о независимости наблюдений. При использовании перестановочного теста в нулевую гипотезу входят следующие предположения о процессе, генерирующем данные:

- Все генерируемые выборки имеют один и тот же размер m.
- Вектора переменных $X_1, \ldots, X_n$ считаются детерминированными, то есть нвектора X-описаний для всех генерируемых выборок одинаковы и равны $\mathbf{x}_1, \ldots, \mathbf{x}_m$
- значениz Y генерируются случайно и независимо из маргинальных эмпирического распределения $\hat{E}_y$. Такая генерация совпадает с выборкой с возвращением.

Перестановочный тест. Обоснование.

Нулевая гипотеза H_0 заключается в предположении о генерации данных описанным выше процессом.

- Процесс отбирает выборки значений переменной Y, которые совпадают по размеру с выборкой $\widetilde{S}$ и распределению на ней значений Y

Theorem

Предположим, что $N_1^p[T(\widetilde{S})]$ число таких отличающихся друг от друга перестановок y-частей описаний объектов из $\widetilde{S}$ при фиксированных $\mathbf{x}-$частях, при которых для результирующей выборки $\widetilde{S}'$ справедливо неравенство $T(\widetilde{S}') \geq T(\widetilde{S})$. Тогда справедливо равенство

$$P[T(\widetilde{S}' \geq T(\widetilde{S})|H_0] = \frac{N_1^p[T(\widetilde{S})]}{m!} \tag{2}$$

Перестановочный тест. Обоснование.

Доказательство Обозначим через $W^p(\widetilde{S})$ множество выборок, генерируемых описанным выше процессом. Разобьём $W^p(\widetilde{S})$ на группы неразличимых выборок $\widetilde{G}_1, \ldots, \widetilde{G}_{N_d}$. Выборки $\widetilde{S}'$ и $\widetilde{S}''$ считаются тождественнными, если значения Y на объектах с одинаковым номером равны. Доказательство опирается на 3 утверждения.

- 1) Вследствие неразличимости величина статистики T на всех выборках внутри каждой из групп постоянна.
- 2)Число перестановок позиций $y-$частей описаний выборки при фиксированных $\mathbf{x}-$частях, с помощью которых могут быть получены все выборки из группы является одинаковым для всех групп.
- 3)Вероятности появления каждой из групп одинаковы.

Перестановочный тест. Обоснование.

Доказательство пункта 1) очевидно.
Докажем пункт 2). Предположим,что Y в $\widetilde{S}$ принимает значения $k \leq m$ значений. Пусть $l_1, \ldots, l_k$ являются количествами объектов в $\widetilde{S}$, на которых Y принимает значения $\breve{y}_1, \ldots, \breve{y}_k$ соответственно. Любая перестановка, переводящая $\widetilde{S}$ в произвольную перестановку из группы G_u является произведением некоторой перестановки π_{0u}, осуществляющей переход в одну из выборок из G_u и перестановки из $\widetilde{\pi}_u$, где $\widetilde{\pi}_u$ является множеством перестановок, сохраняющих принадлежность G_u. Число перестановок в $\widetilde{\pi}_u$ не зависит от номера группы u и равна $T_g = \prod_{i=1}^{k} l_i!$.

Перестановочный тест. Обоснование.

При случайной и независимой генерации Y из маргинальных эмпирического распределения $\hat{E}_y$ вероятности всех групп также равны между собой $\prod_{i=1}^{k} P^{l_i}(\breve{y})$. Дополнительный отбор сохраняет равновероятность. Вследствие этого $P(G_u) = \frac{1}{N_d}$ для всех u.

$$P[T(\widetilde{S}' \geq T(\widetilde{S})|H_0] = \frac{\sum_{u \in U[T(\widetilde{S})]} P(G_u)}{\sum_{u=1}^{N_d} P(G_u)}, \tag{3}$$

где $U[T(\widetilde{S})]$-множество номеров групп, для выборок которых выполняется условие $T(\widetilde{S}') \geq T(\widetilde{S})$ Домножим числитель и знаменатель левой части равенства (3) на $T_g N_d$. В результате и получаем равенство (2).

Перестановочный тест. Преимущества и недостатки.

На правктике вместо подсчёта всевозможных перестановок используется их подмножество, получаемо с помощью случайной генерации перестановок. Использование нескольких тысяч перестановок позволяет достаточно точно оценивать $p-$значения.

- Преимущества. Безусловно преимуществом перестановочного теста является отсутствие требований к типу вероятностных распределений, а также отсутствие требований к размеру выборок. Преимуществом также является гибкость. Для использования необходимо только предположить вид зависимости и подобрать характеризующую данную зависимость статистику. Не требуется аналитически восстанавливать распределение статистики.
- Недостатки Основным недостатком перестановочного теста является привязанность его к конкретным данным. Тест может приводить к ошибочным заключениям при сильном, но статистически возможным,отклонении от генеральной совокупности. Другим недостатком являетсянеобходимость больших объемов вычислений.

Проблема множественного тестирования

Целью многих исследований в различных областях науки является выяснение, какие показатели из некоторого заранее заданного набора $X_1, \ldots, X_n$ связаны с целевой переменной Y.
Стандартной процедурой устанавления связи переменной X_j с Y является проверка нулевой гипотезы H_0^j об отсутствии связи, которая сводится к сравнению рассчитанного $p-$значения с некоторым заранее заданным уровнем значимости α: H_0^j отвергается, если выполняется неравенство $p \leq \alpha$.
При применении указанной процедуры к одной единственной переменной X_j вероятность ошибки первого рода, то есть вероятность ошибочного опровержения нулевой гипотезы равнв α.

Проблема множественного тестирования

Нулевые гипотезы об отдельных эффектах, связанных с конкретными переменными далее будем называть индивидуальными. Допустим, что индивидуальная нулевая гипотеза отвергнута для хотя бы одной переменных из $X_1, \ldots, X_n$. В этом случае уверенность вывода о действительном существовании найденных связей с Y связана с вероятностью ошибочного отвержения по крайней мере одной из множества на самом деле верных индивидуальных нулевых гипотез. Такую вероятность принято называть family wise error rate (FWER). Обозначим через V общее число ошибочно отвергнутых нулевых гипотез.Тогда $FWER = P(V \geq 1)$. Очевидно, что FWER зависит от уровня значимости, на котором отвергаются индивидуальными гипотезы.

Проблема множественного тестирования

Наряду с FWER для оценки множественноно тестирования могут быть использованы также другие меры. Пусть R - общее число отвергнутых индивидуальных нулевых гипотез.

- PCER (per-comparison error rate) - математическое ожидание доли ошибок первого рода $\frac{E(V)}{n}$
- PFER(per-family error rate) - математическое ожидание ошибок первого рода $E(V)$
- FDR(false discovery rate) - математическое ожидание доли ошибок первого рода среди отвергнутых индивидуальных нулевых гипотез. Поскольку R может принимать нулевые значения, то FDR определяется как $E(\frac{V}{R}|R > 0)P(R > 0)$

Проблема множественного тестирования

Аналогично тому, как для оценивания значимости отдельных связей проверяется неравенство $p \leq \alpha$, для оценки значимости с учётом эффекта множественного тестирования может проверяться неравенство $FWER \leq \alpha$. Попытаемся оценить вероятность случайного отвержения по крайней мере одной из нулевые гипотез $H_0^1, \ldots, H_0^n$ на уровне не хуже β.

Обозначим через $\Omega_j^{r\beta}$-множество выборок данных, генерируемых при справедливости нулевой гипотезы H_0^j, при которых эта гипотеза отвергается на уровне β.

FWER, то есть вероятность, что хотя бы одна одна из гипотез H_0^j будет ошибочно отвергнута на уровне β очевидно равна $P(\cup_{i=1}^n \Omega_j^{r\beta})$

Проблема множественного тестирования. Коррекция по Бонферрони

Для оценки сверху вероятности $P(\cup_{i=1}^{n}\Omega_j^{r\beta})$ может быть использовано неравенство Буля

$$P(\cup_{i=1}^{n}\Omega_j^{r\beta}) \leq \sum_{i=1}^{n} P(\Omega_j^{r\beta})$$

Однако $P(\Omega_i^{r\beta}) = \beta$ по определению множества $\Omega_i^{r\beta}$. Поэтому

$$P(\cup_{i=1}^{n}\Omega_j^{r\beta}) \leq n\beta$$

Откуда следует, что для выполнения требования $FWER \leq \alpha$ достаточно, чтобы выполняось неравенство $n\beta \leq \alpha$ или $\beta \leq \frac{\alpha}{n}$. Определяемое последним неравенством требование к уровню значимости, на котором отвергаются индивидуальные нулевые гипотезы, носит название поправки Бонферрони.

Проблема множественного тестирования. Коррекция по Бонферрони

Требование выполнения неравенства $\beta \leq \frac{\alpha}{n}$, эквивалентно использованию вместо исходных $p-$значений скорректированных $p-$значений. Скорректированное $p-$значение для нулевой гипотезы H_0^j вычисляется через исходное $p-$значение как $\widetilde{p}_j = \min(np_j, 1)$. Скорректированное $p-$значение является минимальной ошибкой первого рода, при которой нулевая гипотеза отвергается с учётом поправки на множественное тестирование.

Видно, метод Бонферрони выдвигает весьма жёсткие требования к уровню значимости, на котором отвергается индивидуальная нулевая гипотеза. Например, для положительного заключения о существовании связи между переменной X_j и целевой переменной Y на уровне 0.01 необходимо, чтобы соответствующая индивидуальная нулевая гипотеза была отвергнута на уровне $\frac{0.01}{n}$.

Проблема множественного тестирования. Метод Шидака

Метод Шидака. В подходе Шидака предполагается, что $p-$значения $p_1, \ldots, p_n$, соответствующие индивидуальными нулевым гипотезам $H_0^1, \ldots, H_0^n$. являются взаимонезависимыми случайными величинами, подчиняющимися равномерному распределению на отрезке $[0, 1]$. Скорректированное $p-$значение в методе Шидака вычисляется по формуле

$$\widetilde{p}_j = 1 - (1 - p_j)^n$$

Оценки по методу Шидака являются корректными только при выполнении неравенства Шидака для совместного распределения статистик, используемых оценивании индивидуальные нулевые гипотезы

$$Pr(|T_1| \leq c_1, \ldots, |T_n| < c_n) \geq \sqcap_{j=1}^n Pr(|T_j| \leq c_j).$$

Неравенство Шидака справедливо в частности для многомерных нормальных распределений.

Проблема множественного тестирования. Одношаговые процедуры

Недостатком методов Бонферрони и Шидака являётся учёт при при вычислении скорректированной значимости отвержения нулевой гипотезы H_0^j только лишь исходного нескорректированного $p-$значения,а также общего числа исходных нулевых гипотез. При этом не учитывается исходные $p-$значения для остальных индивидуальных нулевых гипотез помимо H_0^j. Подобные процедуры принято называть одношаговыми (single step). Одной из возможных способов задания одношаговых процедур является подход Вестфолла и Янга (Westfall and Youg)в котором рассчитанные $p-$значения рассматриваются как реализации случайных величин $P_1, \ldots, P_n$. При этом скорректированное значение определяется по формуле

$$\widetilde{p}_i = P(\min_{1 \le l \le n} P_l \le p_i | H_u), \tag{4}$$

Проблема множественного тестирования. Одношаговые процедуры

где H_u является пересечением всех индивидуальных нулевых гипотез $H_u = \cap_{j=1}^{n} H_0^j$. В случае, когда для всех индивидуальных нулевых гипотез распределения статистик критерия близки скорректированное значение может приближённо вычиляться по формуле:

$$\widetilde{p}_i = P(\max_{1 \le l \le n} T_l \ge t_i | H_u). \tag{5}$$

Предполагается, что рассчитанные значения статистик критерия для каждой из нулевых гипотез $t_1, \ldots, t_n$ являются реализация случайных функций $T_1, \ldots . T_n$ соответственно.
Для вычисления скорректированных значений согласно формулам (4,5) может быть использован также перестановочный тест.

Проблема множественного тестирования. Перестановочный тест.

Предположим, что у нас имеется обучающая выборка $\widetilde{S} = \{(y_1, \mathbf{x}_1) \ldots, (y_m, \mathbf{x}_m)\}$. Тре буется проверить n нулевых гипотез $H_0^1, \ldots, H_0^n$ о независимости целевой переменной Y от каждой из переменных $X_1, \ldots, X_n$ с помощью некоторой статистики T. Сгенерируем множество $\widetilde{f}_N$ из N случайных независимых перестановок чисел из $\{1, \ldots, m\}$: $\widetilde{f}_N = \{f_j | j = 1, \ldots, N\}$. Для выборки $\widetilde{S}_r^j = \{(y_{f_j(1)}, \mathbf{x}_1), \ldots, (y_{f_j(m)}, \mathbf{x}_m)\}$ вычислим статистику

$$T_{max}^j = \max_{i \in \{1, \ldots, n\}} T_i(\widetilde{S}_r^j).$$

Скорректированое согласно формуле (5) $p-$значение может быть оценено с помощью модифицированного варианта формулы 1:

$$\widetilde{p}_i = \frac{\sum_{j=1}^{N} I[T_{max}^j \geq T_i(\widetilde{S})]}{N}.$$

Пусть $p_1(\widetilde{S}), \ldots, p_n(\widetilde{S})$ являются $p-$значениями, рассчитанными по выборке $\widetilde{S}$ с помощью описанной ранее процедуры, соответствующей формуле (1). Скорректированое согласно формуле (4) $p-$значение может быть оценено как

$$\widetilde{p}_i = \frac{\sum_{j=1}^{N} I[\hat{P}_{min}^j \leq p_i(\widetilde{S})]}{N},$$

где $\hat{P}_{min}^j = \min_{i \in \{1,\ldots,n\}} p_i(\widetilde{S}_r^j)$

Проблема множественного тестирования. Метод Холма

Для получения более точных оценок скорректированной значимость эффекта, связанного с отвержением индивидуальной нулевой гипотезы H_0^j, необходимо учитывать исходные $p-$значения для всех индивидуальных нулевых гипотез. Проводить такой учёт позволяют процедуры пошагового спуска (step down). Одной из таких процедур является метод метод Бонферрони-Холма.

Предположим, что для нулевых гипотез $H_0^1, \ldots, H_0^n$ рассчитаны $p-$значения $p_1, \ldots, p_n$. Пусть $p^{(1)}, \ldots, p^{(n)}$ - ряд упорядоченных по возрастанию $p-$значений и $H_0^{(1)}, \ldots, H_0^{(n)}$ - ряд соответствующих нулевых гипотез.

Зафиксируем уровень значимости α.

Проблема множественного тестирования. Метод Холма

Предположим, что h - минимальный индекс,удовлетворяющий условию:

$$p^{(h)} > \frac{\alpha}{n+1-h}. \tag{6}$$

Тогда нулевые гипотезы $H_0^{(1)}, \ldots, H_0^{(h-1)}$ отвергаются, а нулевые гипотезы $H_0^h, \ldots, H_0^n$ принимаются. В случае, когда $h = 1$ принимаются все нулевые гипотезы. В случае, когда не существет $h \in 1, \ldots, m$, при котором выполняется неравенство (6), то отвергаются все нулевые гипотезы $H_0^{(1)}, \ldots, H_0^{(n)}$.

Теорема Вероятность случайного отклонения по крайней мере одной из истинных нулевых гипотез по процедуре Бонферрони-Холма оценивается на уровне $p < \alpha$.

Доказательство Предположим, что из n нулевых гипотез истинными являются n_0 гипотез. Предположим, что H_0^h первая по счёту гипотеза, которая была отвергнута ошибочно. Тогда гипотезы $H_0^{(1)}, \ldots, H_0^{(h-1)}$ являются ложными Справедливо неравенство

$$h - 1 \leq n - n_0$$

и, следовательно,

$$\frac{1}{n - h + 1} \leq \frac{1}{n_0}$$

Поскольку гипотеза отвергнута, то

$$p^{(h)} \leq \frac{\alpha}{n - h + 1} \leq \frac{\alpha}{n_0}$$

Однако вероятность случайного отклонения по крайней мере одной из n_0 нулевых гипотез на уровне $p < \frac{\alpha}{n_0}$ оценивается согласно методу, используемому при получении оценок Бонферрони, на уровне $p < \alpha$.

Проблема множественного тестирования. Использование FDR.

Для оценки скорректированного уровня значимости с учётом всей совокупности исходных $p-$значений для индивидуальных нулевых гипотез также может быть использован индекс FDR. Предположим, что используется процедура, при которой индивидуальные нулевые гипотезы отвергаются, если соответствующее исходное $p-$значение не превышает β. Оценим предполагаемое число ошибок первого рода при условии справедливости всех нулевых гипотез $H_0^1, \ldots, H_0^n$. Если предполагаать независимость соответствующих статистик, то в качестве оценки может быть использовано произведение βn.
Предположим, что настоящее число отвергнутых нулевых гипотез составило n'.
Опровержение этих гипотез нельзя считать случайным, если βn многократно меньше n'. Предположим, что

$$\frac{\beta n}{n'} \leq \delta \tag{7}$$

Проблема множественного тестирования. Использование FDR.

Неравенство (7) означает, что ожидаемая доля ошибок первого рода среди отвергнутых гипотез не превышает δ. Естественно оценивать на уровне δ скорректированную значимость индивидуальной гипотезы, которая исходно отвергается на уровне β. Величина $\frac{\beta n}{n'}$ фактически является оценкой FDR.

Временные ряды.Основные понятия

По временным рядом понимается понимается совокупность наблюдений некоторой величины X в различные моменты времени из некоторого интервала $[0, T]$. При этом чаще всего предполагается, что время наблюдения t принимает целочисленные значения из отрезка $[0, T]$.Предполагается, что каждый рассматриваемый временной ряд является реализацией дискретного случайного или стохастического процесса.

Каждому целочисленному моменту времени $t \in [0, T]$ ставится в соответсттвие случайная величина X_t. Дискретным стохастическим процессом понимается совокупность всех таких случайных величин. Временной ряд называется реализацией дискретного стохастического процесса, если значение ряда в момент времени t является реализацией случайной величины X_t.

Часто имеет смысл трактовать последовательность $\{X_t, t \in [0, T]\}$ как подпоследовательность бесконечной последовательности $\{X_t, t = \ldots, -2, -1, 0, 1, 2, \ldots\}$.
Очевидно, что стохастический процесс полностью характеризуется совокупностью плотностей совместных распределений случайных величин вида $f(x_{t_1}, \ldots, x_{t_n})$, где $t_1, \ldots, t_n$– некоторый набор моментов наблюдений.

Строгая стационарность

Стохастический процесс называется строго стационарным или стационарным в узком смысле, если для произвольного набора моментов наблюдения $t_1, \ldots, t_n$ и для произвольного целочисленного Δ справедливо равенство

$$f(x_{t_1}, \ldots, x_{t_n}) = f(x_{t_1+\Delta}, \ldots, x_{t_n+\Delta})$$

Из строгой стационарности следует

- Независимость от t математического ожидания EX_t, то есть $\forall t \in Z \; EX_t$ равно некоторой одной и той же величине μ

Строгая стационарность

- Независимость от t дисперсии $E(X_t - \mu)^2$, то есть $\forall t \in Z$ $E(X_t - \mu)^2$ равно некоторой одной и той же величине σ^2
- Автоковариционная функция (значение ковариации между случайными величинами, соответствующими двум разными моментами времени t_1 и t_2) зависит только от разности $t_1 - t_2$

Последний вывод следует из выполнения при произвольном целочисленном Δ равенства

$$Cov(X_{t_1}, X_{t_2}) = \int\int (x_{t_1} - \mu)(x_{t_2} - \mu) f(x_{t_1}, x_{t_2}) dx_{t_1} dx_{t_2} =$$

$$= \int\int (x_{t_1} - \mu)(x_{t_2} - \mu) f(x_{t_1+\Delta}, x_{t_2+\Delta}) dx_{t_1} dx_{t_2}$$

Слабая стационарность

Под слабой стационарностью или стационарностью процесса в широком смысле понимается процесс, для которого математическое ожидание и дисперсия не зависят от времени, а автоковариационная функция зависит только от разности моментов времени $t_1 - t_2$. Слабая стационарность также называется иногда также стационарностью в ковариациях.

Примеры случайных процессов

Под белым шумом понимается случайный процесс, в котором $X_t = \epsilon_t$, где $\forall t\ E\epsilon_t = 0$, $E\epsilon^2$ равен некоторой фиксированной величине σ^2, $\forall t_1 \neq t_2\ Cov(\epsilon_{t_1}, \epsilon_{t_2}) = 0$. Очевидно, что белый шум является стационарным в широком смысле. Белый шум называется гауссовым, если для произвольной конечной последовательности моментов наблюдений $t_1, \ldots, t_n$ каждая из случайных величин $\epsilon_{t_1}, \ldots, \epsilon_{t_n}$ подчиняется нормальному распределению. Гауссов шум является стационарным также и в узком смыле(или в ковариациях).

Примеры случайных процессов. Процесс случайного блуждания.

Под процессом случайного блуждания понимается процесс, в котором $X_t = X_{t-1} + \epsilon_t$, где ϵ_t-белый шум. Предположим, что в момент времени $t = 0$ значение временного ряда, являющегося реализацией случайного процесса, составило x_0. Очевидно, что значение процесса в момент времени T является случайной величиной, представимой в виде

$$X_T = x_0 + \sum_{t=1}^{T} \epsilon_t$$

Математическое ожидание случайной величины $X_T - x_0$ может быть представлено в виде

$$E(X_T - x_0) = EX_t - x_0 = \sum_{t=1}^{T} E(\epsilon_t) = 0,$$

то есть $EX_T = x_0$.

Процесс случайного блуждания.

Дисперсия X_T очевидно равна

$$E(X_t - x_0)^2 = \sum_{t=1}^{T} \sum_{t'=1}^{T} E(\epsilon_{t'} \epsilon_t)$$

Предположим, что дисперсия белого шума равна σ^2. Тогда очевидно, учитывая независимость $\epsilon_{t'}$ и $\epsilon_{t'}$,

$$E(X_T - x_0)^2 = \sum_{t=1}^{T} E(\epsilon_t^2) = T\sigma^2$$

Таким образом, дисперсия случайного блуждания в конце интервала пропорциональна длине этого интервала.
Процесс случайного блуждания очевидно является нестационарным.

Детерминированная и случайная компонента стохастического процесса

Любой стохастический процесс Y_t может быть представлен в виде $Y_t = D_t + X_t$, где D_t- детерминированная компонента, вычисляемая как функция от момента времени, X_t-случайная компонента.
Детерминированная компонента может быть представлена в виде суммы тренда R_t и сезонной компоненты S_t: $D_t = R_t + S_t$.
Линейный тренд: $R_t = \alpha + \beta t$, обычно выделяется на каком-то достаточно продолжительном интервале времени.
Сезонная компонента: $S(t) = A\cos(\omega t + \phi)$ представляет циклические изменения с фиксированыым периодом. Процесс, в котором присутствует сезонная компонента стационарным не являетсяю

Теорема Вольда

Любой стационарный в ковариациях процесс может быть представлен в виде

$$X_t = \mu + \sum_{j=0}^{\infty} b_j \epsilon_{t-j},$$

где ϵ_t-белый шум, μ - математическое ожидание процесса. Следует отметить, что значения коэффициентов b_j зависят только от задержки j и не зависят от времени t. Сходимость по вероятности суммы

$$\sum_{j=0}^{\infty} b_j \epsilon_{t-j}$$

обеспечивается при существовании конечного предела $\sum_{j=1}^{n} |b_j|$ при $n \to \infty$

Операторное представление временного ряда

Одним из инструментов работы с временными рядами является использование оператора временного сдвига L. Действие оператора L заключается в переходе от значения переменной в точке t к значению этой же переменной в точке $t-1$: $LX_t = X_{t-1}$, $L\epsilon_t = \epsilon_{t-1}$.
Действие оператора L^k заключается в последовательном применении k раз оператора L: $L^k X_t = X_{t-k}$
Естественным образом вводится сложение операторов и умножения оператора на число: $aL^k X_t = aX_{t-k}$,
$(a_1 L^{k_1} + a_2 L^{k_2})X_t = a_1 X_{t-k_1} + a_2 X_{t-k_2}$

Операторное представление временного ряда

Условие

$$X_t = a_1 X_{t-1} + \ldots + a_n X_{t-n} + \epsilon_t$$

очевидно эквивалентно условию

$$(1 - a1L - \ldots - a_n L^n) X_t = \epsilon_t.$$

Для операторных представлений временных рядов справедлив аналог основной теоремы алгебры.

$$(1 - a1L - \ldots - a_n L^n) X_t = -a_n [\prod_{i=1}^{n} (L - Z_i)] X_t,$$

где $Z_1, \ldots, Z_n$ - корни характеристического уравнения

$$1 - a_1 Z - \ldots - a_n Z^n = 0$$

Операторное представление временного ряда. Единичные корни.

Предположим, что единичный характеристический корень $Z = 1$ имеет кратность r. Тогда характеристическое уравнение представимо в виде

$$B(z)(1 - Z)^r = 0.$$

А для операторного представлениния справедливо уравнение

$$B(L)(1 - L)^r X_t = \epsilon_t.$$

Обозначим через ΔX_t - временной ряд, состоящий из разностей

$$\ldots, X_{t-1} - X_{t-2}, X_t - X_{t-1}, X_{t+1} - X_t, \ldots$$

Получение последнего временного ряда назовём операцией дифференцирования. Через $\Delta^r X_t$ обозначим r-кратное применение операции дифференцирования. В случае, если $r = n$ справедливо равенство $\Delta^r X_t = \epsilon_t$. То есть ряд $\Delta^r X_t | t \in Z$ является стационарным.

,

Процесс скользящего среднего

Стохастический процесс называется процессом скользящего среднего или moving average (MA(q)), если

$$X_t - \mu = \sum_{j=0}^{q} b_j \epsilon_{t-j},$$

где μ-математическое ожидание X_t. Название "скользящее среднее"связано с тем, что значение процесса в момент t является взвешенным средним по значениям белого шума в q предшествующих моментах времени. Математическое ожидание процесса MA(q) очевидно равно 0.
Дисперсия процесса MA(q) может быть выражена через сумму квадратов коэффициентов b_j

$$E(X_t - \mu)^2 = \sigma^2 \sum_{j=0}^{q} b_j^2.$$

Процесс скользящего среднего

Очевидно, дисперсия процесса не зависит от t.
Ковариация случайных величин $x_t = X_t - \mu$ и $x_{t+\tau} = X_{t+\tau} - \mu$ может быть вычислена по формуле

$$cov(x_{t+\tau}, x_t) = \sigma^2 \sum_{j=0}^{q-\tau} b_j b_{j+\tau}$$

при $\tau \leq q$. При $\tau > q$ $cov(x_{t+\tau}, x_t) = 0$. Таким образом для процесса MA(q) удовлетворяются все три тебования стационарности в ковариациях.

Процесс авторегрессии-скользящего среднего

Случайный процесс называется процессом авторегрессии, еслиего значение в точке t является суммой белого шума в точке t и линейной комбинацией значений этого процесса в предшествующие моменты времени.

$$X_t = a_1 X_{t-1} + a_2 X_{t-2} + \ldots + a_p X_{t-p} + \epsilon_t$$

Процесс авторегрессии представленного вида обозначается AR(p) Вообще говоря процесс авторегрессии не обязательно является стационарным в ковариациях. При исследовании и прогнозировании временных рядов принято рассматривать объединённый процесс авторегрессии-скользящего среднего

$$X_t = a_1 X_{t-1} + a_2 X_{t-2} + \ldots + a_p X_{t-p} + b_1 \epsilon_{t-1} + b_2 \epsilon_{t-2} + \ldots$$

$$+ b_q \epsilon_{t-q} + \epsilon_t$$

Прогнозирование временного ряда

Эффективное прогнозирование времнного ряда очевидно возможно при наличии в нём долговременных трендов или сезонных колебаний. Для того, чтобы использовать при прогнозировании наличие линейного тренда, достаточно найти по имеющемуся временному ряду коэффициенты линейной регрессионной модели $X_t = \alpha + \beta t + \epsilon$. Это можно сделать, например, с помощью метода наименьших квадратов. Учёт сезонных колебаний может быть осуществлён через подсчёт средних значений по множеству точек временного ряда, сооответствующих одинаковой фазе цикла. В случае, если временной ряда является стационарным в ковариациях, для прогнозирования могут использоваться математические модели, основанные процесса авторегрессии-скользящего среднего.
Предварительным этапом, обеспечивающим успех моделирования, является переход от исходного необязательно стационарного ряда к стационарному.

Оценка стационарности

Проверка стационарности может производится через анализ автокорреляций с различной величиной лага. Автокорреляция с лагом k вычисляется как

$$r_k = \frac{\sum_{t=k+1}^{n}(X_t - \bar{X})(X_{t-k} - \bar{X})}{T\hat{D}^2},$$

где $\bar{X}$- среднее значение , $\hat{D}$ - дисперсия X на интервале наблюдения, n-длина ряда. Если временной ряд является стационарным, то r_k должны убывать и приближаться к 0 с увеличением k. Если с ростом k сохраняются высокие значения r_k, то процесс нестационарен.

Тест Дикки-Фуллера. Случайный процесс может оказаться нестационарным вследствие того, что он является процессом случайного блуждания: $X_t = X_{t-1} + \epsilon_t$. Процесс случайного блуждания также называют процессом с единичным корнем в связи с тем, что одним из корней соответствующего характеристического уравнения является 1.

Оценка стационарности. Тест Дикки-Фуллера

Процесс случайного случайного блуждания очевидно является частным случаем простого процесса авторегрессии

$$X_t = \rho X_{t-1} + \epsilon_t. \tag{8}$$

Уравнение (8) может быть записано в виде

$$\Delta_t = X_t - X_{t-1} = \gamma X_{t-1} + \epsilon_t$$

где $\gamma = \rho - 1$.
Процессу случайного блуждания соответствует $\gamma = 0$ или $\rho = 1$.
Проверка гипотезы о том, соответствует ли некоторый временной ряд процессу случайного блуждания или процессу с единичным корнем, может быть сведена к проверке гипотезы о равенстве 0 коэффициента γ. Процессу случайного блуждания очевидно соответствует характеристическое уравнение с единичным корнем.

Оценка стационарности. Тест Дикки-Фуллера

Проверка равенства $\gamma = 0$ частично аналогична рассматриваемой ранее проверке нулевой гипотезы о равенстве 0 регрессионного коэффициента с помощью теста Стьюдента. Для проверке равенства $\gamma = 0$ используется та же самая статистика. Выполнение неравенств $\rho > 1$ и соответственно $\gamma > 0$ приводит к резкому "взрывному"возрастанию величин X за короткие промежутки времени. Подобные процессы крайне редко встречаются на практике. Поэтому на практике актуальной оказывается проверка гипотезы $\gamma = 0$ против альтернативы $\gamma < 0$. То есть используется односторонний критерий.

Переход к стационарным временным рядамю

Переход к стационарным временным рядам может быть произведён с помощью взятия разностей двух следующих друг за другом элементов.

- Очевидно, что разности двух соседних элементов процесса случайного блуждания $\Delta X_t = X_t - X_{t-1} = \epsilon_t$ составляют стационарный ряд, являющщийся белым шумом.
- Рассмотрим также нестационарный случайный процесс $X_t = \alpha + \beta t + \gamma t^2 + \epsilon_t$. Разность двух последующих элементов, которую мы наовём разностью первого порядка, может быть записана как

$$\Delta X_t = \alpha + \beta t + \gamma t^2 - \alpha - \beta(t-1) - \gamma(t-1)^2 + \epsilon_t - \epsilon_{t-1}$$

Переход к стационарным временным рядам

- Разность двух последующих элементов ряда, составленного из разностей первого порядка,(разность второго порядка) может быть записана в виде

$$\Delta^2 X_t = \Delta X_t - \Delta X_{t-1} = 2\gamma + \epsilon_t - 2\epsilon_{t-1} + \epsilon_t$$

  Таким образов, ряд, составленный из разностей второго порядка является стационарным.

Последовательное взятие разностей увеличивающегося порядка является универсальным средством достижения стационарности.

Переход к стационарным временным рядам

Временной ряд называется интегрированным порядка k, если временной ряд, составленный из разностей порядка k ($\Delta^k X_t$), является стационарным. Наличие стационарности порядка k для ряда X_t обозначается $X_t \sim I(k)$. Временной ряд, удовлетворяющий условию $X_t \sim I(0)$ очевидно является стационарным.
Процесс случайного блуждания является процессом $\sim I(1)$.

Прогнозирование временного ряда с использованием модели авторегрессии-скользящего среднего.

Будем проводить последовательное взятие разностей между соседними элементами временного ряда до тех пор, пока не определим порядок его интегрированности k.
Далее для прогнозирования временного ряда $\{Y_t = \Delta^k X_t | t = 1, \ldots, m\}$ будем использовать модель авторегрессии-скользящего среднего:

$$Y_t = \sum_{i=1}^{p} a_i Y_{t-i} + \sum_{j=1}^{q} b_j \epsilon_{t-j} + \epsilon_t \tag{9}$$

Для того, чтобы можно было прогнозировать значение процесса в точке t очевидно необходимо знать величины $p, q, a_1, \ldots, a_p, b_1, \ldots, b_q$.

Прогнозирование временного ряда с использованием модели авторегрессии-скользящего среднего.

Поиск значений p, q проводится через изучение графика автокорреляционной функции (ACF) и частной автокорреляционной функции (PACF). ACF является функцией натурального аргумента и определяется точке i как коэффициент корреляции Пирсона между Y_t и Y_{t-i}: $\gamma(i) = \rho(Y_t, Y_{t-i})$. PACF также является функцией натурального аргумента и описывает линейную связь между Y_t и Y_{t-i} за вычетом влияния Y_t всех элементов ряда, находящихся между Y_t и Y_{t-i}. Значение PACF в точке i определяется как коэффициент корреляции Пирсона между величинами Y_{t-i} $Y_t - \sum_{j=1}^{i} \phi_j Y_{t-j}$, где

$$(\phi_1, \ldots, \phi_{i-1}) = arg\min[\sum_{t=i}^{m}(Y_t - \sum_{j=1}^{i-1} \phi_j Y_{t-j})^2].$$

Прогнозирование временного ряда с использованием модели авторегрессии-скользящего среднего.

Величины p и q подбираются из условия выхода на приблизительно нулевой уровень соответственно ACF $\gamma(i)$ и PACF $\gamma_p(i)$.
Предположим, что величины p, q заданы. Тогда для поиска оптимальных значений $a_1, \ldots, a_p, b_1, \ldots, b_q$ может быть использована следующая схема.

- Зададим некоторое некоторое конечное множество $\widetilde{B}$ векторов значений параметров $b_1, \ldots, b_q$, внутри которого предполагается проводить поиск

Процесс авторегрессии-скользящего среднего. Поиск регрессионных параметров

- Зафиксируем некоторый $\mathbf{b}^* \in \widetilde{B}$
- Ведём новые переменные

$$Z_1 = X_1, Z_2 = X_2 - b_1^* Z_1, \ldots, Z_k = X_k - \sum_{i=1}^{q-1} b_i^* Z_{k-i}, \ldots \tag{10}$$

- $\forall t$ справедливо

$$Z_t = \sum_{i=1}^{p} a_i Z_{t-i} + \epsilon_t. \tag{11}$$

Условия справедливости данного факта будет обсуждаться ниже. Поскольку все значения Z вычисляются по временному ряду, то коэффициенты $a_1, \ldots, a_p$ могут быть найдеы исходя из требования минимизции

$$\sum_{i=1}^{n} \epsilon_i^2 = \sum_{t=1}^{n} (Z_t - \sum_{i=1}^{p} a_i Z_{t-i})^2$$

.

Операторная форма представления случайного процесса

- Повторим два предыдущих пункта при различных значениях $\mathbf{b} \in \widetilde{B}$ и выберем $\mathbf{b}$ при котором $\sum_{t=1}^{n} \epsilon_t^2$

Справедливость равенства $Z_t = \sum_{i=1}^{p} a_i Z_{t-i} + \epsilon_t$ при произвольном t может быть показана через представление процессов AR(p) и MA(q) с использованием оператора сдвига L. Процесс AM(q) может быть представлен в виде операторного полинома

$$X_t = (1 + b_1 L + \ldots + b_q L^q)\epsilon_t$$

Операторная форма представления случайного процесса

Процесс авторегрессии очевидно может быть представлен в виде

$$X_t = (a_1 L + a_2 L^2 + \ldots, a_p L^p) X_t + \epsilon_t$$

Процесс ARMA(p,q) может быть задан уравнением

$$(1 - a_1 L - \ldots - a_p L^p) X_t = (1 + b_1 L + \ldots + b_q L^q) \epsilon_t$$

Откуда следует, что

$$X_t = \frac{(1 + b_1 L + \ldots + b_q L^q) \epsilon_t}{1 - a_1 L - \ldots - a_p L^p}$$

Последнее справедливо только, если обратный оператор к оператору $1 - a_1 L - \cdots - a_p L^p$ действительно существует.

Поиск параметров ARMA(p,q)

Пусть $Z_t = \frac{\epsilon_t}{1-a_1L-\ldots-a_pL^p}$.
Тогда $(1 - a_1L - \ldots - a_pL^p)Z_t = \epsilon_t$, что эквивалентно (11)
$X_t = (1 + b_1L + \ldots + b_qL^q)Z_t$, что эквивалентно (10).
После того, как установлены величины p и q, а также коэффициенты $a_1, \ldots, a_p$ и $b_1, \ldots, b_q$, необходимо оценить адекватность полученнной модели.
Диагностика модели естественно должна производится по величинам остатков. Из определения процесса ARMA следует, что величины $\epsilon_1, \ldots, \epsilon_T$ являются белым шумом. Откуда следует независимость остатков и следовательно близость 0 значений автокорреляционной функции.
Для проверки правильности выбора сложности модели, то есть количеств слагаемых p и q принято использовать информационнын критерии: информационный критерий Акаике (AIC) или байесовский информационный критерий Шварца (BIC).

Проблема "ложных"регрессий в многомерных временных рядах.

Под многомерным временным рядом понимается ряд, содержащий в каждой временной точке значения нескольких переменных $\{X_t^1, \ldots, X_t^k | t = 0, \ldots, T\}$.
Наряду с задачами прогнозирования значений переменных,входящих в многомерный временной ряд, нередко возникают задачи изучения взаимосвязи этих переменных между собой. Например, линейная взаимосвязь может изучаться путём вычисления коэффициентов корреляции Пирсона для пар переменных. Влияние переменных $X^{i_1}, \ldots, X^{i_r}$ на переменную X^{i_y} исследуется через построение соответствующей регессионной модели.
Вместе с тем многочисленные расчёты показывают относительно частую встречаемость ситуаций, когда

Проблема "ложных"регрессий в многомерных временных рядах.

- коэффициент корреляции между двумя переменными X^i и X^j из одного и того же временного ряда имеет высокую статистическую значимость при оценивании последней при использовании стандартных средств верификации
- одномерные временные ряды, содержащие отдельно значения переменных X^i и X^j, остаются нестационарными даже после исключения из него тренда и сезонной периодичности
- наличие корреляции между X^i и X^j не поддаётся объяснению в рамках соответствующих научных дисциплин

Аналогичные ситуации нередко возникают и для более сложных регрессионных моделей, при тестировании последних с помощью стандартных статистических критериев.

Проблема "ложных"регрессий в многомерных временных рядах.

Возрастание вероятности чисто случайного возникновения связей, формально оцениваемы как статистически достоверные с использованием стандартных статистических тестов,подтверждаются в экспериментах с искусственно сгенерированнными данными. Например, при многократном искусственном генерировании временных рядов значений переменных X^i и X^j с использованием процесса случайного блуждания при нормально распределённой случайной компоненте ϵ_t, доля рядов со значением коэффициента корреляции $\rho(X^i, X^j) \in C$, где C является критической областью двухсторонненго критерия Стьюдента для уровня значимости α существенно превышает саму величину α.

Коинтеграция

С целью повышения достоверности регрессионного анализа на временным рядах при нестационарности целевой переменной Y_t и регрессоров $X_t^1, \ldots, X_t^k$, Грэйнджером был предложено дополнительное требование стационарности остатков регрессионной модели $Y_t = \sum_{i=1}^k \beta_i X_t^i + r_t$. То есть вводилось требование стационарности ряда

$$Y_t - \sum_{i=1}^{k} \beta_i X_t^i. \tag{12}$$

Требование стационарности ряда (12) является тождественным требованию коинтеграции. Пусть $\{Z_t^1, \ldots, Z_t^k\}$ является совокупностью интегрированных по первому порядку временных рядов, т.е. $Z_t^i \sim I(1), i = 1, \ldots, k$

Коинтеграция

Временной ряд $\{Z_t^1, \ldots, Z_t^k\}$ называе0тся коинтегрированным, если существует такой вектор $(a_1, \ldots, a_k)$, что временной ряд $u_t = \sum_{i=1}^k a_i Z_t^i$ является стационарным процессом, т.е $u_t \sim I(0)$.
Очевидно, что требование коинтеграции в последнем смысле является фактически эквивалентным условию стационарности остатков в смысле (12) из-за того, что свойство стационарности не теряется при умножении ряда на произвольную константу.
Наличие коинтеграции между переменными говорит о существовании определённой связи между ними, несмотря на случайный непредсказуемый характер изменений каждой из них.